

Trabalho prático em grupo – Módulo 2

Cinthia Mie Ungefehr¹[PG58422], Fabiano de Carvalho e Sousa¹[PG55213], João
Pedro da Silva Barbosa¹[PG58984], and Lóren Narrane Leandro Oliveira da
Silva¹[PG61985]

¹ Universidade do Minho, Largo do Paço, 4704-553, Braga

Abstract. A Colangiopancreatografia Retrógrada Endoscópica (CPRE) é um procedimento utilizado para o diagnóstico e tratamento de patologias dos dutos biliares e pancreáticos que combina técnicas de endoscopia e fluoroscopia permitindo a visualização em tempo real das estruturas anatómicas através de imagens de raio-x. O objetivo deste projeto consiste no desenvolvimento e otimização de modelos de aprendizagem profunda capazes de classificar automaticamente imagens fluoroscópicas de CPRE.

Keywords: Raio-x · Deep Learning · Classificação

1 Introdução

A Colangiopancreatografia Retrógrada Endoscópica (CPRE) é um procedimento minimamente invasivo utilizado para o diagnóstico e tratamento de patologias dos dutos biliares e pancreáticos. O exame combina técnicas de endoscopia e fluoroscopia permitindo a visualização em tempo real das estruturas anatómicas através de imagens de raio-x. A CPRE desempenha um papel fundamental na identificação e tratamento de condições como cálculos biliares, fugas de biliar, estenoses dos dutos e determinadas neoplasias pancreatobiliares [1].

Nos últimos anos, a aplicação de técnicas de Inteligência Artificial (IA) e Aprendizagem Profunda (*Deep Learning*) à imagem médica tem demonstrado resultados promissores no apoio ao diagnóstico clínico. No contexto da CPRE, o desenvolvimento destes sistemas tem sido limitado pela escassez de conjuntos de dados públicos e devidamente anotados, dificultando a criação de métodos reprodutíveis e comparáveis.

O objetivo deste projeto consiste no desenvolvimento e otimização de modelos de *Deep Learning* capazes de classificar automaticamente imagens fluoroscópicas de CPRE em quatro categorias diagnósticas:

- Biliary_Leaks - *Bile Leaks*, Fugas de biliar;
- Lithiasis - *Biliary lithiasis, Stones*, Cálculos biliares/Pedras;
- Stricture - *Strictures*, Estenoses dos dutos biliares/Aperto dos dutos biliares;
- Normal - Achados normais/Ausência de alterações patológicas relevantes.

Para tal, será utilizado o subconjunto anotado do dataset MIQR-CC, disponibilizado juntamente ao artigo [2]. Adicionalmente, pretende-se comparar os resultados obtidos neste projeto com a baseline apresentada pelos autores do artigo, F1-Score macro de 0.738 através da arquitetura EfficientNet-B7, procurando superar esse desempenho.

2 Dataset

Para a realização deste trabalho foi utilizado o dataset MIQR-CC, um conjunto de imagens fluoroscópicas obtidas durante procedimentos de CPRE [2]. O dataset contém 19.018 imagens originais e 19.317 imagens pré-processadas, representando exames de 1.571 pacientes (observa-se uma pequena discrepância em relação aos 1.602 pacientes relatado no artigo original).

As imagens disponibilizadas abrangem diferentes fases do procedimento de CPRE, incluindo imagens pré-canulação utilizadas para orientação anatómica, imagens adquiridas durante a injeção de contraste e manobras terapêuticas, bem como imagens obtidas após a intervenção para documentação do resultado final.

Segundo o artigo relacionado, o conjunto de dados inclui um subconjunto de 5.519 imagens anotadas por gastroenterologistas com mais de 5 anos de experiência, permitindo a sua utilização em tarefas de classificação automática supervisionada.

As anotações originais contemplam as seguintes categorias clínicas: *Biliary Lithiasis*, *Biliary Leaks*, *Benign Strictures*, *Malignant Strictures* e *Normal Findings*.

2.1 Pré-Processamento do Dataset

Antes da disponibilização pública, as imagens foram sujeitas a um processo de pré-processamento. As imagens classificadas como do tipo V (*Vertical*) continham múltiplos frames fluoroscópicos numa única imagem composta. Para estas imagens foi aplicado um processo automático baseado em detecção de linhas verticais, segmentação e validação dos segmentos obtidos, permitindo a extração de imagens individuais.

Por outro lado, as imagens classificadas como S (Single Frame) foram sujeitas principalmente a procedimentos de anonimização, incluindo um corte quadrado central e a aplicação de uma máscara circular, removendo potenciais informações identificáveis presentes nas margens da imagem.

Para o problema em mãos, as categorias *Benign Stricture* e *Malignant Stricture* foram agrupadas numa única classe designada por Stricture.

Além disso, uma exploração inicial da base permitiu visualizar algumas características acerca da qualidade das imagens. Das imagens coletadas, 4.101 foram classificadas como “Discard” na coluna “Keep” e 13.798 como “Unlabelled” na coluna “Label”. A remoção dos casos com essas características resultou na base utilizada para treinamento dos modelos com um total de 1.568 imagens válidas representando 436 pacientes únicos.

Destes pacientes, 228 são do sexo feminino e 208 são do sexo masculino, com concentração de idade dos pacientes entre 63 (primeiro quartil) e 83 (terceiro quartil) anos com mediana em 74 anos de idade.

2.2 Divisão dos Dados

A divisão dos dados foi realizada segundo a estratégia disponibilizada pelos autores do dataset, utilizando uma proporção de 70% para treino, 15% para validação e 15% para teste.

O processo de divisão implementa uma estratificação a nível do paciente, garantindo que todas as imagens pertencentes ao mesmo indivíduo permanecem no mesmo subconjunto. Esta abordagem evita situações de *data leakage* e preserva a distribuição das classes entre os diferentes conjuntos de dados. A Table 1, a seguir, apresenta a distribuição final das classes pelos subconjuntos de treino, teste e validação.

Table 1. Tabela de Distribuição final das classes pelos subconjuntos

Classe	Treino	Teste	Validação
Lithiasis	505	98	123
Stricture	255	53	84
Normal	197	59	43
Biliary Leaks	110	24	17

3 Metodologia de Tratamento de Imagem

A classificação automática de imagens médicas constitui um problema desafiante devido à heterogeneidade das imagens, às variações de contraste e às diferenças entre equipamentos de aquisição. No contexto de imagens fluoroscópicas de CPRE, estas dificuldades são agravadas pela sobreposição de estruturas anatômicas e pela reduzida distinção visual entre determinadas patologias.

Para execução desse trabalho foi utilizada a linguagem de programação Python 3.13 com as bibliotecas Pandas, PyTorch, MONAI, Matplotlib, entre outras. Os códigos gerados estão disponíveis no GitHub por meio do repositório: https://github.com/CinthiaNagahama/MMC_AP_Trabalho.

Historicamente, dois tipos de modelos têm demonstrado elevado desempenho em tarefas de classificação de imagens: as Redes Neurais Convolucionais (CNNs) e os *Vision Transformers* (ViTs) [3]. As CNNs destacam-se pela sua capacidade de extrair padrões espaciais locais, enquanto os *Transformers* permitem modelar relações globais na imagem.

Neste trabalho, foi adotada uma estratégia baseada em transfer learning, explorando modelos pré-treinados em grandes bases de dados genéricas, nomeadamente ImageNet 1K, bem como arquiteturas disponibilizadas em bibliotecas especializadas como TorchVision [4] e MONAI [5]. Esta abordagem permite acelerar a convergência do treino e melhorar a generalização do modelo em datasets médicos de menor dimensão.

Foram avaliadas diversas arquiteturas, abrangendo diferentes níveis de complexidade e paradigmas de aprendizagem:

Table 2. Tabela de Modelos Pré-Treinados no ImageNet 1k

Modelo	Acc@1	Acc@5	Parâmetros
ResNet-50	80.858%	95.434%	25.6M
ResNeXt-50-32x4D	81.198%	95.34%	25.0M
ResNeXt-101-32x8D	82.834%	96.228%	88.8M
ConveNeXt-B	84.062%	96.87%	88.6M
DenseNet-121	74.434%	91.972%	8.0M
EfficientNet-V2-S	84.228%	96.878%	21.5M
VGG19	72.376%	90.876%	143.7M
ViT-B-16	85.304%	97.65%	86.9M

Para adaptação ao domínio específico das imagens fluoroscópicas de CPRE e para aumentar artificialmente o tamanho do *dataset*, foi aplicado um conjunto de técnicas de pré-processamento e *data augmentation*. Estas incluem:

- Redimensionamento das imagens para dimensão compatível com cada arquitetura (de 224x224 a 512x512, dependendo da arquitetura);
- Random crop para introdução de variabilidade espacial;
- Transformações geométricas leves (rotação no eixo x com valores até 30° e zoom em intervalos de 0.9 a 1.1);
- Ajustes de contraste;
- Adição controlada de ruído gaussiano (*gaussian noise*);
- Adição de desfoque gaussiano (*gaussian blur*);
- Normalização baseada na média e desvio padrão do conjunto de treino.

Os parâmetros exatos destas transformações foram ajustados experimentalmente, variando conforme a arquitetura utilizada e os resultados obtidos.

Adicionalmente, para lidar com o desbalanceamento das classes presentes no *dataset* MIQR-CC, foram utilizadas funções de perda adaptadas, nomeadamente *Cross Entropy Loss* com pesos de classe e a *Focal Loss*. O processo de otimização foi realizado utilizando os algoritmos *Adam* e *AdamW*, amplamente utilizados no treino de redes neurais profundas devido à sua estabilidade e rapidez de convergência.

4 Modelos e Arquiteturas

Foram testadas diversas arquiteturas e combinações de hiperparâmetros. Por questão de tempo disponível e a limitação de *hardware*, os hiperparâmetros foram escolhidos manualmente com foco em melhorar o F1-Score das arquiteturas mais promissoras. A Table 3, a seguir, mostra os hiperparâmetros do melhor modelo para cada arquitetura testada:

Table 3. Tabela de Modelos Testados


Arquitetura	Loss	Otimizador	Épocas	Learning Rate	F1-Score (Validação)	F1-Score (Teste)
EfficientNet-B7	Cross-Entropy	AdamW	12	1e-5	0.48	0.762
ResNet-50	Cross-Entropy	AdamW	15	3e-4	0.703	0.745
EfficientNet-V2-S	Focal	Adam	13	1e-4	0.573	0.727
ViT-B-16	Focal	Adam	13	1e-5	0.51	0.634
ResNeXt-101-32x8D	Focal	Adam	4	1e-4	0.562	0.556
ResNeXt-50- 32x4D	Focal	Adam	4	1e-4	0.612	0.544
ConveNeXt-B	Focal	Adam	4	1e-4	0.619	0.47
DenseNet-121	Focal	Adam	31	1e-5	0.582	0.464
VGG19	Focal	Adam	1	1e-4	0.171	0.251

5 Resultados Obtidos pelos Melhores Modelos

5.1 EfficientNet-B7

Assim como no artigo original do MIQR-CC, o melhor F1-Score de teste após o *fine-tuning* (0,762) foi de uma EfficientNet-B7. Contudo, no caso do presente trabalho, percebe-se uma forte divergência deste valor em relação ao F1-Score de teste (0,48).

O modelo demonstrou capacidade de aprendizagem de padrões específicos de exames de CPRE, destacando-se na identificação das classes Normal e Lithiasis. Nota-se, contudo, uma confusão persistente entre as classes Stricture e Lithiasis, possivelmente decorrente da semelhança visual destas patologias, vide Fig. 1.

**Fig. 1.** Matriz de confusão do EfficientNet-B7

5.2 ResNet-50

Em segundo lugar, mas com resultados mais consistentes entre o F1-Score de teste e o de validação, esperava-se uma melhor generalização nesse modelo. Contudo, analisando a matriz de confusão (Fig. 2), é possível perceber que esse modelo apresenta comportamento semelhante ao anterior.




Fig. 2. Matriz de confusão do ResNet-50

5.3 EfficientNet-V2-S

O último modelo do pódio, essa EfficientNet-V2-S apresenta discrepância similar a da EfficientNet-B7 quanto aos F1-Scores de treino e validação, porém com uma capacidade aparentemente melhor de generalizar que os modelos anteriores, como é possível ver na Fig. 3.




Fig. 3. Matriz de confusão do EfficientNet-V2-S

Para avaliar esse resultado um tanto inesperado, utilizou-se o Grad-CAM para visualização das áreas consideradas importantes pelo modelo. Como pode ser visto na Fig. 4, o modelo priorizou as regiões de onde se encontra o contraste.




Fig. 4. Visualização de interpretabilidade (Grad-CAM)

Devido a esses pontos, esse modelo foi selecionado para a execução do experimento descrito no tópico 6.1.

6 Experimentos

Com o objetivo de auxiliar no desenvolvimento de modelos mais competitivos, foram realizadas duas atividades exploratórias pelo grupo neste projeto.

6.1 Aplicação de medidas de agregação nos resultados da classificação

A partir da análise exploratória dos metadados das imagens processadas no trabalho anterior [2], notou-se que, dos 436 pacientes distintos relacionados às imagens válidas, apenas 47 possuem duas ou mais classificações diferentes no seu conjunto de imagens. Ou seja, a ampla maioria de 389 pacientes recebeu apenas uma classificação em todo o seu conjunto de imagens e, portanto, pode ser considerada como pacientes com resultados consistentes.

Já entre os 47 pacientes sem resultados consistentes, a maioria possui o seu conjunto de imagens quase que na totalidade classificado em uma das 3 classes (*Biliary Leaks*, *Lithiasis* ou *Stricture*), mas com 1 ou 2 imagens classificadas como “Normal”. Ou seja, mesmo para estes, há a dominância de uma classificação única.

A Table 4 apresenta a melhora de desempenho com a aplicação de pós-processamento pela moda nos resultados por paciente do melhor modelo gerado em [2] e do melhor neste trabalho.

Table 4. Resultados antes e depois da aplicação da agregação pela moda do paciente nos dados de teste.

Arquitetura	Accuracy (%)	Precision (macro %)	Recall (macro %)	F1-score (macro)
EfficientNet_V2_S (Original)	78.28	73.29	73.25	0.727
EfficientNet_V2_S (Pós-Agregação)	81.65 (+3.37)	77.45 (+4.16)	80.40 (+7.15)	0.778 (+0.051)
EfficientNet-B7 (Original)	78.28	75.26	75.33	0.738
EfficientNet-B7 (Pós-Agregação)	88.39 (+10.11)	85.53 (+10.27)	85.57 (+10.24)	0.847 (+0.109)

O ganho estatisticamente significativo de performance indica a forte correlação entre as classificações intra-paciente, que poderia ser melhor estimada com a aplicação de um modelo de agregação de predições ao nível do paciente, ou *Prediction Aggregation Model*, com resultados ainda melhores do que a aplicação da moda.

Para fins de desenvolvimento de agente de classificação de imagens como assistente *real time* em procedimentos de exame ERCP, fica inviável que esta correlação de classificações de imagens intra-paciente seja completamente capturada ao se tratar como *input* do modelo uma imagem de cada vez.

6.2 Classificador XGBoost sobre espaço latente reduzido da imagem gerado por modelo *Conditional Variational Auto-Encoder* (CVAE)

Num experimento distinto, buscou-se elaborar uma solução baseada em CVAE com a dupla intenção de:

1. ser utilizada para geração de novas imagens, a partir do *decoder* por *sampling* do espaço latente das imagens de treino; e
2. poder compactar as imagens em um espaço latente significativamente menor, o que possibilita a experimentação de um classificador XGBoost cujo *input* consiste do resultado do espaço latente da imagem acrescido da informação de idade e sexo do paciente e do equipamento utilizado no exame. O desenvolvimento desta solução baseada em CVAE foi dividido em 4 etapas distintas executadas em ordem, como em uma competição de modelos:

- **Etapla 0 — Modelo CVAE de referência**

Objetivo: adaptar ao domínio do projeto e às redes convolucionais o código de CVAE desenvolvido em aula para o *MNIST* com *MLP*.

Configuração: modelo CVAE sem uso de *transfer learning*, com espaço latente de dimensão 32. O encoder é composto por uma rede de convoluções 2D, enquanto o decoder utiliza camadas *ConvTranspose*.

Otimizador e hiperparâmetros: Fixados em todos os modelos CVAE, Learning rate= 1e-4 com ReduceLROnPlateau, Batch_size = 16, optimizer = torch.optim.Adam e recuperação da *epoch* com menor loss = l1_loss + beta x kl_loss . No caso de modelos com *transfer_learning*, os parâmetros pré-treinados são inicialmente congelados, com *unfreeze* das 2 últimas camadas na *epoch* 12, seguida de *unfreeze* de mais uma cada na *epoch* 25.

Notebooks: CVAE_Conv32Base.ipynb

- **Etapla 1 — Avaliação do tamanho do espaço latente**

Objetivo: verificar se o aumento da dimensionalidade do espaço latente melhora o desempenho do classificador XGBoost.

Configuração: treinamento de três versões do modelo com espaços latentes de dimensões 64, 128 e 256.

Resultado: não foi observado ganho significativo de desempenho. Assim, optou-se por manter o modelo com espaço latente de dimensão 64.

Notebooks: CVAE_Conv64.ipynb vs CVAE_Conv128.ipynb vs CVAE_Conv256.ipynb

- **Etapla 2 — Avaliação de transfer learning**

Objetivo: investigar o impacto da utilização de modelos pré-treinados no encoder.

Configuração: comparação entre o modelo vencedor da etapa anterior e duas variantes com *transfer learning*, baseadas em EfficientNet-B0 e em ResNet50, todas com espaço latente de dimensão 64.

Resultado: não foi observado ganho de desempenho. Dessa forma, manteve-se o modelo com espaço latente de dimensão 64 sem *transfer learning*.

Notebooks: CVAE_Conv64.ipynb vs CVAE_EFFI64.ipynb vs CVAE_RES64.ipynb

- **Etapa 3 — Inclusão de imagens não classificadas**

Objetivo: verificar se a utilização de um conjunto de treino significativamente maior de imagens do domínio, porém sem rótulos, contribui para um encoder com representação latente mais discriminatória para o XGBoost.

Configuração: comparação entre o modelo vencedor da etapa anterior treinado apenas com imagens classificadas e uma versão treinada acrescida de 13.649 imagens não classificadas (*unlabelled*).

Resultado: não foi observado ganho de desempenho. Assim, manteve-se o modelo com espaço latente de dimensão 64 treinado exclusivamente com imagens classificadas.

Notebooks: CVAE_Conv64.ipynb vs CVAE_Conv64F.ipynb

- **Etapa 4 — Geração de modelo específico para *data augmentation***

Objetivo: obter um encoder e decoder mais atentos aos detalhes de resolução fina das imagens, uma vez que as imagens geradas pelos CVAEs consistentemente apresentavam fundos borrados, com perda de detalhes.

Configuração: aumentou-se em 20 vezes o espaço latente, para tamanho 2056, e desprezou-se a necessidade de resultados pelo XGBoost.

Resultado: o modelo foi treinado com uso de filtros *transforms* diferentes dos utilizados nos demais modelos deste projeto e, portanto, as imagens geradas, sob efeito destes filtros, não puderam ser usadas de forma coerente para treino como *data augmentation*. Não foi possível treinar novamente com filtros corrigidos.

Notebooks: CVAE_Conv2056.ipynb

Os *notebooks* de cada modelo, com exemplos de imagens geradas e outras informações de performance, como curva de aprendizagem e matriz de confusão, podem ser vistos em `Modulo_2/Dev/fabiano` do github.

O classificador XGBoost em todas as etapas foi treinado com o uso do *framework* Optuna para otimização de hiperparâmetros. Apesar disso, foi observado que o melhor modelo obtido sempre estava em *overfitting* e, infelizmente, isso não foi corrigido. Esta desatenção possivelmente prejudicou o fluxo de comparação entre modelos, mas, de partida, os resultados obtidos estão em Table 5.

Table 5. Resultados no XGBoost dos espaços latentes dos modelos CVAE avaliados.

Arquitetura CVAE	Espaço latente	Tam. FC enc/dec	Parâm. treinados	Época	XGBoost (macro)		
					Teste		Validação
					Accuracy	F1-score	F1-score
CONV32Base	32	65k	6,8 M	11	37,8%	0,309	0,37
CONV64	64	65k	14,3 M	47	45,3%	0,310	0,32
EFFI64	64	1.280	4,8 M	47	29,6%	0,226	0,30
RES64	64	2.048	4,9 M	40	34,8%	0,252	0,34
CONV128	128	65k	26,9 M	89	32,6%	0,245	0,44
CONV256	256	20k×65k	271,4 M	98	44,9%	0,399	0,28
CONV64Full	64	65k	14,3 M	10	36,0%	0,264	0,30
CONV2056	2.056	98.304	611,4 M	97	44,6%	0,356	0,44

Finalmente, acredita-se que este experimento poderia ser significativamente melhorado com a repetição de toda a sequência de etapas acima, com os ajustes necessários para evitar o *overfitting* no XGBoost, o uso de espaços latentes maiores nos CVAEs experimentados e a correção dos filtros da etapa 4.

7 Conclusão

O objetivo deste projeto consistia no desenvolvimento e otimização de modelos de Deep Learning capazes de classificar automaticamente imagens fluoroscópicas de CPRE em quatro categorias diagnósticas.

No fim, foi possível obter resultados superiores a *baseline* definida tanto com o experimento 1 quanto sem ele, porém uma análise mais aprofundada dos resultados torna possível perceber que os modelos treinados não generalizam bem para a classe minoritária Biliary Leaks além de apresentarem resultados melhores nos dados de teste em relação aos de validação, indicando que a distribuição dos dados tenha forte influência nesses resultados.

Além disso, a forte presença de falso negativos, torna os modelos não apropriados para uso no contexto médico, já que podem atrapalhar o diagnóstico correto e acarretar em falta de tratamento médico adequado.

Algumas formas de melhorar os resultados seriam a anotação das imagens dadas como “unlabelled” no *dataset* e/ou a adição de mais imagens anotadas ao *dataset* para melhorar os modelos e trazer mais segurança às classificações realizadas.

Como trabalhos futuros, alguns experimentos que podem trazer melhorias para os resultados obtidos seriam:

- Aplicação do MSFE para Feature Extraction [6];
- Ensembles de modelos convolucionais diferentes;
- Investigação a cerca de outros modelos de Transformers [7]; e
- Alterações no pré-processamento para simular imagens da classe minoritária.

Bibliography

- [1] C. Pata, “What is ERCP?.” [Online]. Available: <https://cengizpata.com/en/what-is-ercp/>
- [2] A. J. Andrade, M. Martins, A. Ferreira, T. Araújo, L. Lopes, and V. Alves, “Curated Endoscopic Retrograde Cholangiopancreatography Images Dataset.” [Online]. Available: <https://arxiv.org/abs/2601.16759>
- [3] R. Aggarwal and S. Hayes, “Image Classification: State-of-the-Art Models in 2025.” [Online]. Available: <https://madailab.com/image-classification-state-of-the-art-models-in-2025>
- [4] PyTorch, “Models and pre-trained weights.” [Online]. Available: <https://docs.pytorch.org/vision/main/models.html>
- [5] MONAI, “Project MONAI.” [Online]. Available: <https://project-monai.github.io/>
- [6] H. R. Nabil, I. Ahmed, A. Das, M. Mridha, M. M. Kabir, and Z. Aung, “MSFE-GallNet-X: a multi-scale feature extraction-based CNN Model for gallbladder disease analysis with enhanced explainability.” [Online]. Available: <https://pmc.ncbi.nlm.nih.gov/articles/PMC12399013/#Abs1>
- [7] E. Randellini, “Image classification: ResNet vs EfficientNet vs EfficientNet_v2 vs Compact Convolutional Transformers.” [Online]. Available: <https://medium.com/@enrico.randellini/image-classification-resnet-vs-efficientnet-vs-efficientnet-v2-vs-compact-convolutional-c205838bbf49>

